

## **КРИПТОГРАФІЯ**

### **КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1**

**Експериментальна оцінка ентропії на символ джерела відкритого тексту**

Виконали:

ФБ-04 Ковальчук Єгор

ФБ-04 Омелянович Олександр

## Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

## Порядок виконання роботи

0. Уважно прочитати методичні вказівки до виконання комп'ютерного практикуму.

1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку  $H_1$  та  $H_2$  за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення  $H_1$  та  $H_2$  на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де імовірності замінити відповідними частотами. Також одержати значення  $H_1$  та  $H_2$  на тому ж тексті, в якому вилучено всі пробіли.

2. За допомогою програми CoolPinkProgram оцінити значення  $(10) H$ ,  $(20) H$ ,  $(30) H$ . 3. Використовуючи отримані значення ентропії, оцінити надлишковість російської мови в різних моделях джерела.

## Хід виконання роботи

Був взятий для виконання текст перших двох творів Анджея Сапковського із серії “Відьмак”, спершу було створено файл із оригінальним текстом, потім було перетворено його у текст тільки із маленькими буквами, та вирізано букви “ё” та “ъ”, також було прибрано всі множинні пробіли, цей текст занесено у файл “clear\_text.txt”.

Після цього була створена ще одна копія цього тексту, але без пробілів взагалі і записано у файл “withoutspaces.txt”.

Було пораховано кількість, частоту та ентропію для кожної монограми для тексту з пробілами/без пробілів.

Було пораховано кількість, частоту та ентропію для кожної біграми з перетинами/без перетинів для тексту з пробілами/без пробілів.

Всі ці дані було занесено у excel файл з назвою “result.xlsx”, та уже в ньому було пораховано загальну ентропію та надлишковість.

## Результати

Монограми з пробілами

Ентропія = 4,406383

$R = 0,118723$

Монограми без пробілів

Ентропія = 4,491052

$$R = 0,093485$$

Біграми з перетинами і пробілами

$$\text{Ентропія} = 4,011989$$

$$R = 0,197602$$

Біграми з перетинами без пробілів

$$\text{Ентропія} = 4,182021$$

$$R = 0,155863$$

Біграми без перетин з пробілами

$$\text{Ентропія} = 4,012104$$

$$R = 0,197579$$

Біграми без перетин без пробілів

$$\text{Ентропія} = 4,18171$$

$$R = 0,155926$$

### Найчастіші монограми та біграми

| Монограми з пробілами |            |
|-----------------------|------------|
| "                     |            |
| "                     | 0,16019534 |
| о                     | 0,08862054 |
| е                     | 0,07026795 |
| а                     | 0,06917973 |
| н                     | 0,05388906 |
| и                     | 0,05247785 |
| т                     | 0,05102193 |
| л                     | 0,04500444 |
| с                     | 0,03937553 |
| р                     | 0,03915292 |
| в                     | 0,03554243 |
| к                     | 0,03149764 |
| у                     | 0,02627222 |
| д                     | 0,02599694 |
| м                     | 0,02527046 |
| п                     | 0,0229221  |
| ь                     | 0,01915956 |
| я                     | 0,01874514 |
| ы                     | 0,01688872 |
| г                     | 0,01596448 |
| з                     | 0,01499353 |
| б                     | 0,01463775 |
| ч                     | 0,0126402  |
| й                     | 0,0093517  |
| ж                     | 0,00868486 |

| Монограми без пробілів |            |
|------------------------|------------|
| о                      | 0,10552518 |
| е                      | 0,08367178 |
| а                      | 0,08237598 |
| н                      | 0,06416856 |
| и                      | 0,06248817 |
| т                      | 0,06075452 |
| л                      | 0,05358918 |
| с                      | 0,04688654 |
| р                      | 0,04662146 |
| в                      | 0,04232226 |
| к                      | 0,03750592 |
| у                      | 0,03128373 |
| д                      | 0,03095593 |
| м                      | 0,03009088 |
| п                      | 0,02729457 |
| ь                      | 0,0228143  |
| я                      | 0,02232084 |
| ы                      | 0,02011029 |
| г                      | 0,01900975 |
| з                      | 0,01785359 |
| б                      | 0,01742994 |
| ч                      | 0,01505136 |
| й                      | 0,01113557 |
| ж                      | 0,01034152 |
| ш                      | 0,00970368 |

|   |            |
|---|------------|
| ш | 0,0081492  |
| х | 0,00719216 |
| ю | 0,00585649 |
| щ | 0,00348229 |
| э | 0,00334713 |
| ц | 0,00285421 |
| ф | 0,00136549 |

|   |            |
|---|------------|
| х | 0,00856409 |
| ю | 0,00697363 |
| щ | 0,00414655 |
| э | 0,00398561 |
| ц | 0,00339866 |
| ф | 0,00162596 |

| Біграми з перетинами і пробілами |             | Біграми з перетинами без пробілів |             |
|----------------------------------|-------------|-----------------------------------|-------------|
| о                                | 0,019419367 | то                                | 0,014330371 |
| а                                | 0,017497307 | на                                | 0,01189325  |
| е                                | 0,01692685  | не                                | 0,011394936 |
| н                                | 0,0161139   | ал                                | 0,011263551 |
| п                                | 0,015901222 | по                                | 0,011106127 |
| и                                | 0,015724321 | ст                                | 0,011069434 |
| в                                | 0,013965248 | но                                | 0,010674097 |
| с                                | 0,013435538 | ко                                | 0,010297698 |
| я                                | 0,011784793 | ра                                | 0,010032562 |
| то                               | 0,011633731 | ен                                | 0,00982069  |

| Біграми без перетин з пробілами |             | Біграми без перетин без пробілів |             |
|---------------------------------|-------------|----------------------------------|-------------|
| о                               | 0,019327512 | то                               | 0,014425353 |
| а                               | 0,017528726 | на                               | 0,012113036 |
| е                               | 0,016837038 | не                               | 0,011412478 |
| п                               | 0,01596249  | по                               | 0,01121367  |
| и                               | 0,015910812 | ал                               | 0,011114267 |
| н                               | 0,01582932  | ст                               | 0,011052731 |
| в                               | 0,013829785 | но                               | 0,010510745 |
| с                               | 0,013386548 | ко                               | 0,010162833 |
| я                               | 0,011726895 | ра                               | 0,01001136  |
| то                              | 0,011707018 | ен                               | 0,009859888 |

## Програма CoolPinkProgram

Лабораторная работа №1

Произвольная часть текста:  
\_убегают\_

Использованные буквы:

Порядок n-граммы:  
5 символов  
15 символов  
20 символов  
25 символов  
30 символов  
35 символов  
40 символов  
45 символов  
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 52

Неравенство для энтропии:  
 $2,43452033014597 < H < 3,17469832265279$

Двоичная таблица угаданных символов:

|                                  |
|----------------------------------|
| 00000000000000000000000000000000 |
| 10000000000000000000000000000000 |
| 10000000000000000000000000000000 |
| 00000000000000000000000000000000 |
| 00000001000000000000000000000000 |

Вероятности:

|                    |
|--------------------|
| $q[1] = 0,3137254$ |
| $q[2] = 0,2352941$ |
| $q[3] = 0,0980392$ |
| $q[4] = 0,0196078$ |
| $q[5] = 0,0392156$ |
| $q[6] = 0,0196078$ |
| $q[7] = 0,0196078$ |
| $q[8] = 0,0588235$ |
| $q[9] = 0$         |
| $q[10] = 0,019607$ |
| $q[11] = 0,019607$ |
| $q[12] = 0$        |
| $q[13] = 0,039215$ |
| $q[14] = 0$        |
| $q[15] = 0,019607$ |
| $q[16] = 0$        |
| $q[17] = 0$        |
| $q[18] = 0$        |
| $q[19] = 0$        |
| $q[20] = 0,019607$ |
| $q[21] = 0,019607$ |
| $q[22] = 0,019607$ |
| $q[23] = 0$        |
| $q[24] = 0$        |
| $q[25] = 0$        |
| $q[26] = 0,019607$ |
| $q[27] = 0$        |
| $q[28] = 0$        |
| $q[29] = 0$        |
| $q[30] = 0,019607$ |
| $q[31] = 0$        |
| $q[32] = 0$        |

Строка состояния:

$$R = 0,439078134720124$$

Лабораторная работа №1

Произвольная часть текста:  
ласны\_точно\_так\_же\_

Использованные буквы:

Порядок n-граммы:  
5 символов  
10 символов  
15 символов  
20 символов  
25 символов  
30 символов  
35 символов  
40 символов  
45 символов  
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Неравенство для энтропии:  
 $1,26702342561981 < H < 2,03073846238439$

Двоичная таблица угаданных символов:

|                                  |
|----------------------------------|
| 10000000000000000000000000000000 |
| 00100000000000000000000000000000 |
| 10000000000000000000000000000000 |
| 01000000000000000000000000000000 |
| 00100000000000000000000000000000 |

Вероятности:

|                |
|----------------|
| $q[1] = 0,58$  |
| $q[2] = 0,12$  |
| $q[3] = 0,12$  |
| $q[4] = 0,04$  |
| $q[5] = 0,06$  |
| $q[6] = 0$     |
| $q[7] = 0,04$  |
| $q[8] = 0$     |
| $q[9] = 0,02$  |
| $q[10] = 0,02$ |
| $q[11] = 0$    |
| $q[12] = 0$    |
| $q[13] = 0$    |
| $q[14] = 0$    |
| $q[15] = 0$    |
| $q[16] = 0$    |
| $q[17] = 0$    |
| $q[18] = 0$    |
| $q[19] = 0$    |
| $q[20] = 0$    |
| $q[21] = 0$    |
| $q[22] = 0$    |
| $q[23] = 0$    |
| $q[24] = 0$    |
| $q[25] = 0$    |
| $q[26] = 0$    |
| $q[27] = 0$    |
| $q[28] = 0$    |
| $q[29] = 0$    |
| $q[30] = 0$    |
| $q[31] = 0$    |
| $q[32] = 0$    |

Строка состояния:

$$R = 0.67022381119958$$

